PROJETO APLICADO IV

NOME	RA
Ândria Giovana Oliveira Cabeça da Silva	10441204
Beatriz Ribeiro Porto Liberato	10441384
Dalicio Pereira de Novaes Junior	10441535
Gustavo da Conceição Guimarães	10723830
Pedro Lima da Silva Junior	10729027

Análise Preditiva de Casos de Dengue em São Paulo para Apoio às Ações de Saúde Pública

Sumário:

1. Introdução 1
2. Motivação 2
3. Objetivo 3
4. Descrição da base de dados 4
5. Referencial teórico 6
6. Pipeline da Solução..... 7
7. Cronograma.....:..... 8

1. Introdução

A dengue representa um importante desafio para a saúde pública, especialmente em regiões que apresentam condições favoráveis à circulação do vírus e à proliferação do mosquito *Aedes aegypti*. No estado de São Paulo, a ocorrência de novos casos e

o surgimento de períodos epidêmicos reforçam a necessidade de estratégias cada vez mais eficientes para o monitoramento, a prevenção e o controle da doença.

Nesse contexto, o presente trabalho tem como objetivo realizar uma análise dos casos de dengue no estado de São Paulo, utilizando dados epidemiológicos disponibilizados pelo InfoDengue, sistema que reúne informações relacionadas à ocorrência e à evolução da doença nos municípios brasileiros.

A partir desses dados, serão aplicadas técnicas de análise de dados e sistemas analíticos com o propósito de identificar padrões, tendências e possíveis comportamentos futuros da dengue. A utilização de ferramentas de análise e previsão pode contribuir para uma compreensão mais precisa da evolução dos casos ao longo do tempo.

Dessa forma, espera-se que os resultados obtidos possam auxiliar na identificação antecipada de períodos de maior risco e na tomada de decisões relacionadas às ações de prevenção e controle da doença. A proposta não se limita à análise dos casos já registrados, mas busca utilizar os dados disponíveis como instrumento para antecipar cenários e contribuir para respostas mais rápidas e eficientes por parte dos órgãos responsáveis pela saúde pública.

2. Motivações

A motivação para o desenvolvimento deste trabalho está relacionada à necessidade de fortalecer as estratégias de prevenção e enfrentamento da dengue, considerando o reaparecimento de períodos de aumento significativo dos casos e a formação de novos focos de transmissão no estado de São Paulo. A recorrência desses cenários demonstra que, além das ações tradicionais de combate ao mosquito transmissor, é necessário ampliar a utilização de informações e tecnologias capazes de apoiar o planejamento das ações de saúde pública.

Nesse sentido, a análise de dados epidemiológicos apresenta-se como uma importante ferramenta para compreender o comportamento da doença e identificar regiões e períodos que possam apresentar maior risco de transmissão. Por meio da utilização de métodos analíticos e de previsão, busca-se transformar os dados coletados em informações que possam contribuir para uma atuação mais preventiva.

Dessa forma, pretende-se possibilitar que medidas de controle sejam planejadas e direcionadas de maneira antecipada, antes que o aumento dos casos alcance proporções mais graves.

Assim, o trabalho tem como principal motivação contribuir para a redução da propagação da dengue no estado de São Paulo, utilizando a análise de dados como

instrumento de apoio à prevenção. A expectativa é que, por meio da identificação de padrões e da previsão de possíveis cenários, seja possível colaborar para ações mais estratégicas, eficientes e antecipadas, contribuindo para a proteção da população, a melhoria da qualidade de vida e o fortalecimento das ações de saúde pública.

3. Objetivo

Desenvolver um produto analítico preditivo, fundamentado em séries temporais e algoritmos de Aprendizado de Máquina, para antecipar períodos de aumento da incidência de dengue nos municípios do estado de São Paulo, utilizando dados oficiais disponibilizados pelo InfoDengue.

Como objetivos específicos, destacam-se:

- Processar, estruturar e analisar séries temporais de grande volume, integrando variáveis epidemiológicas e climáticas provenientes de fontes oficiais.
- Construir, treinar e avaliar modelos preditivos de *Machine Learning* e abordagens estatísticas capazes de estimar o crescimento dos casos de dengue nos municípios paulistas, buscando identificar antecipadamente períodos de maior risco.
- Desenvolver uma solução executável e reproduzível que possa servir como instrumento de apoio ao planejamento preventivo da rede de saúde pública, contribuindo para a organização e o dimensionamento de recursos, medicamentos e insumos médicos essenciais.
- Atender ao caráter extensionista do projeto e ao alinhamento com o **ODS 3 (Saúde e Bem-Estar)**, promovendo a geração de valor social por meio do compartilhamento dos resultados e dos artefatos analíticos com a comunidade e os gestores públicos.

Justificativa

A dengue configura-se como um dos problemas recorrentes de saúde pública no Brasil, impondo desafios à gestão dos serviços de saúde e podendo provocar sobrecarga nos sistemas de atendimento durante períodos epidêmicos. No estado de São Paulo, fatores populacionais, ambientais e climáticos podem favorecer a proliferação do mosquito transmissor (*Aedes aegypti*), tornando necessário o desenvolvimento de estratégias que contribuam para uma resposta mais rápida e eficiente diante do aumento dos casos.

Nesse contexto, identifica-se a necessidade de ampliar a utilização de estratégias preventivas capazes de auxiliar na antecipação de possíveis períodos de maior incidência da doença. A utilização da Ciência de Dados apresenta-se como uma

oportunidade para transformar dados epidemiológicos e climáticos em informações relevantes para a identificação de padrões e cenários de risco em nível municipal.

Do ponto de vista técnico e metodológico, a proposta utiliza dados oficiais disponibilizados pelo InfoDengue e técnicas de análise de séries temporais e Aprendizado de Máquina. A partir dessas informações, pretende-se desenvolver e avaliar modelos capazes de identificar tendências relacionadas ao comportamento da dengue, além de construir um *pipeline* analítico reproduzível que permita o processamento, a análise e a atualização dos dados utilizados no projeto.

Além da contribuição técnica, o projeto apresenta relevância social por buscar fornecer informações que possam apoiar o planejamento de ações preventivas. Os resultados poderão contribuir para o dimensionamento de recursos da rede de saúde, o planejamento de estoques de medicamentos e insumos e o direcionamento de campanhas de conscientização e prevenção.

Por fim, o projeto está alinhado ao **ODS 3 – Saúde e Bem-Estar**, que busca assegurar uma vida saudável e promover o bem-estar para todos, em todas as idades. Dessa forma, pretende-se utilizar a análise de dados não apenas como ferramenta tecnológica, mas também como instrumento de apoio à saúde pública, contribuindo para ações mais estratégicas, preventivas e eficientes no enfrentamento da dengue nos municípios do estado de São Paulo.

4. Descrição da Base de Dados

A base de dados é um arquivo do formato CSV, contendo os registros do municípios do estado de São Paulo. As colunas são:

- data_ini_SE : Primeiro dia da semana epidemiológica (Domingo)
- SE: Semana epidemiológica
- casos_est : Número estimado de casos por semana usando o modelo de nowcasting (nota: Os valores são atualizados retrospectivamente a cada semana)
- cases_est_min and cases_est_max: Intervalo de credibilidade de 95% do número estimado de casos
- casos: Número de casos notificados por semana (Os valores são atualizados retrospectivamente todas as semanas)
- p_rt1: Probabilidade de (Rt> 1). Para emitir o alerta laranja, usamos o critério p_rt1> 0,95 por 3 semanas ou mais.
- p_inc100k: Taxa de incidência estimada por 100.000

- Localidade_id: Divisão submunicipal (atualmente implementada apenas no Rio de Janeiro)
- nivel: Nível de alerta (1 = verde, 2 = amarelo, 3 = laranja, 4 = vermelho), mais detalhes, consulte (Saiba mais)
- id: Índice numérico
- versao_modelo: Versão do modelo (uso interno)
- Rt: Estimativa pontual do número reprodutivo de casos, ver Saiba Mais
- pop: População estimada (IBGE)
- tempmin: Média das temperaturas mínimas diárias ao longo da semana
- tempmed: Média das temperaturas diárias ao longo da semana
- tempmax: Média das temperaturas máximas diárias ao longo da semana
- umidmin: Média da umidade relativa mínima diária do ar ao longo da semana
- umidmed: Média da umidade relativa diária do ar ao longo da semana
- umidmax: Média da umidade relativa máxima diária do ar ao longo da semana
- receptivo: Indica receptividade climática, ou seja, condições para alta capacidade vetorial. 0 = desfavorável, 1 = favorável, 2 = favorável nesta semana e na semana passada, 3 = favorável por pelo menos três semanas (suficiente para completar um ciclo de transmissão)
- transmissao: Evidência de transmissão sustentada: 0 = nenhuma evidência, 1 = possível, 2 = provável, 3 = altamente provável
- nivel_inc: Incidência estimada abaixo do limiar pré-epidemia, 1 = acima do limiar pré-epidemia, mas abaixo do limiar epidêmico, 2 = acima do limiar epidêmico
- notif_accum_year: Número acumulado de casos no ano

Referencial Teórico

A previsão em séries temporais é essencial na epidemiologia para antecipar picos de contágio com base na dependência temporal dos dados. Esse processo envolve conceitos chave como tendência, sazonalidade e autocorrelação (HYNDMAN; ATHANASOPOULOS, 2021). No contexto da dengue, o desafio conceitual consiste em modelar a relação entre variáveis climáticas (temperatura e umidade) e a incidência de casos ao longo das semanas epidemiológicas.

Na literatura de problemas preditivos semelhantes, métodos estatísticos como o ARIMA (BOX; JENKINS, 1976) são frequentemente utilizados. Sua principal **vantagem** é a interpretação e a estrutura matemática consolidada. Contudo, apresentam como **limitação** a modelagem predominantemente linear, falhando ao capturar as interações não lineares abruptas do clima no ciclo de reprodução do mosquito vetor.

Para superar essas barreiras, algoritmos de Aprendizado de Máquina, como Redes Neurais (RUMELHART et al., 1986) e modelos baseados em árvores (*Ensembles*), tornaram-se o padrão atual. A **vantagem** destas técnicas é a alta flexibilidade e precisão na extração de padrões complexos. Por outro lado, sua **limitação** inclui a exigência de grandes volumes de dados, maior custo computacional e o constante risco de sobreajuste aos dados de treino (*overfitting*).

Uma terceira alternativa abordada pela literatura são os modelos híbridos (ZHANG, 2003), que combinam o ARIMA e as redes neurais. A **vantagem** é a maximização da capacidade preditiva ao unir componentes lineares e não lineares, mas a **limitação** é o aumento drástico na complexidade de implementação e ajuste. A compreensão dessas abordagens e metodologias fundamenta a escolha técnica deste projeto, que visa aplicar modelos de aprendizado de máquina aos dados climáticos e epidemiológicos do InfoDengue para antecipar cenários de risco e apoiar a saúde pública.

Referências

BOX, G. E. P.; JENKINS, G. M. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day, 1976.

HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021.

INFODENGUE. *API: acesso aos dados epidemiológicos*. InfoDengue. Disponível em: https://info.dengue.mat.br. Acesso em: 20 ago. 2026.

RUMELHART, D. E. et al. Learning representations by back-propagating errors. *Nature*, v. 323, p. 533–536, 1986.

ZHANG, G. P. Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, v. 50, p. 159–175, 2003.

Pipeline da Solução

O pipeline é a seção que organiza a solução em etapas encadeadas, que permitem o desenvolvimento de um raciocínio lógico para a análise final. A seguir serão apresentadas as etapas propostas.

1. Obtenção dos dados. Através da API do InfoDengue, iremos coletar os dados com base nos municípios do estado de São Paulo. Iremos capturar uma grande abrangência de período, para capturar com qualidade a sazonalidade.
2. Limpeza dos dados. Após a obtenção, iremos verificar inconsistências nos dados, dados duplicados ou ausentes. Iremos renomear colunas e aglutinar variáveis se necessário.
3. Análise exploratória. Nesta fase iremos fazer o trabalho de exploração básica dos dados, verificação de outliers, a distribuição deles, análises de assimetria e curtose, para validar os dados a serem trabalhados em séries temporais.
4. Separação dos dados. Aqui iremos separar os dados que irão para o conjunto de treinamento e para os de teste.
5. Análise gráfica. Faremos a composição gráfica da sazonalidade, mapas de calor e tendência observáveis. Também será analisado se outras variáveis contribuem para as variáveis alvo, de casos estimados e incidência por 100 mil habitantes.
6. Modelagem. Aqui serão aplicados os modelos estatísticos sobre a base, como ARIMA e outros modelos de aprendizado de máquina.
7. Avaliação. Os modelos serão avaliados de acordo com o seu desempenho, utilizando métricas como o MAE, RMSE e MASE.
8. Interpretação. Será o produto final da análise, avaliando o quão bem os modelos foram em produzir conhecimento útil para a criação de políticas públicas de prevenção da Dengue.

Cronograma Detalhado do Projeto IV

O projeto será desenvolvido em quatro etapas principais. Além das datas de entrega definidas pela disciplina, foram planejadas atividades intermediárias para organizar o desenvolvimento do trabalho e alcançar os objetivos propostos.

Etapa 1 – Entrega em 31/08

03/08 a 09/08 – Formação do grupo e definição do tema:

Formação da equipe e definição do tema “Análise Preditiva de Casos de Dengue em São Paulo para Apoio às Ações de Saúde Pública”.

10/08 a 16/08 – Escolha da base de dados:

Pesquisa e escolha da base de dados sobre os casos de dengue no Estado de São Paulo que será utilizada durante o projeto.

17/08 a 23/08 – Organização do repositório no GitHub:

Criação e organização do repositório para armazenar os códigos, dados, documentos e demais materiais produzidos durante o projeto.

24/08 a 30/08 – Documentação inicial:

Elaboração da documentação inicial, apresentação do projeto, definição dos objetivos e estabelecimento das metas do produto analítico.

31/08 – Entrega da Etapa 1:

Entrega da formação do grupo, definição do tema, escolha da base de dados, organização do repositório no GitHub e documentação inicial.

Etapa 2 – Entrega em 28/09

01/09 a 07/09 – Preparação dos dados:

Organização e tratamento da base de dados para possibilitar a realização das análises.

08/09 a 14/09 – Caracterização da série temporal:

Organização dos casos de dengue ao longo do tempo e identificação das principais características da série temporal.

15/09 a 21/09 – Identificação dos componentes da série temporal:

Análise de tendência, sazonalidade e outras características observadas na evolução dos casos de dengue.

22/09 a 25/09 – Desenvolvimento do processo de investigação:

Descrição das etapas realizadas para obtenção, tratamento, preparação e análise dos dados, documentando o pipeline utilizado no projeto.

26/09 a 27/09 – Levantamento das técnicas:

Pesquisa das técnicas que poderão ser utilizadas para trabalhar com os dados e posteriormente desenvolver os modelos preditivos.

28/09 – Entrega da Etapa 2:

Entrega da caracterização e identificação dos componentes da série temporal, descrição dos processos de investigação e levantamento das técnicas para trabalhar com os dados obtidos.

Etapa 3 – Entrega em 26/10

29/09 a 05/10 – Preparação dos dados para modelagem:

Revisão dos dados e resultados obtidos na etapa anterior e preparação da base para aplicação dos modelos.

06/10 a 11/10 – Definição das técnicas para modelagem:

Escolha das técnicas consideradas mais adequadas para realizar a previsão dos casos de dengue.

12/10 a 18/10 – Implementação dos modelos:

Desenvolvimento e execução dos modelos preditivos selecionados.

19/10 a 22/10 – Avaliação do desempenho:

Avaliação dos modelos utilizando métricas adequadas para verificar a qualidade das previsões.

23/10 a 25/10 – Comparação dos modelos:

Comparação dos resultados e desempenhos apresentados pelos diferentes modelos testados.

26/10 – Entrega da Etapa 3:

Entrega da definição das técnicas de modelagem, implementação dos modelos, avaliação do desempenho e comparação dos desempenhos obtidos.

Etapa 4 – Entrega em 30/11

27/10 a 02/11 – Revisão dos modelos testados:

Revisão dos resultados obtidos na etapa anterior e organização das informações necessárias para a análise final.

03/11 a 09/11 – Análise crítica dos modelos:

Análise das vantagens, limitações e diferenças encontradas entre os modelos testados.

10/11 a 15/11 – Discussão do modelo com melhor resultado:

Análise mais detalhada do modelo que apresentou o melhor desempenho e discussão dos resultados obtidos.

16/11 a 20/11 – Proposição de melhorias futuras:

Identificação de possíveis melhorias no projeto e sugestões para aperfeiçoamento futuro do modelo preditivo.

21/11 a 24/11 – Preparação do produto construído:

Organização do produto analítico desenvolvido e dos principais resultados alcançados durante o projeto.

25/11 a 27/11 – Documentação final e organização dos artefatos:

Finalização da documentação e organização dos códigos, dados, resultados e demais arquivos produzidos.

28/11 a 29/11 – Revisão e preparação da apresentação:

Revisão geral do trabalho e preparação da apresentação final do produto construído.

30/11 – Entrega da Etapa 4:

Entrega da análise crítica dos modelos testados, discussão dos resultados do modelo de melhor desempenho, proposição de melhorias futuras, apresentação do produto construído, documentação final e entrega dos artefatos.